Privacy-Preserving E-commerce Data Pipeline — Project Planning

> Documento de referencia con las decisiones de diseño y el roadmap acordado.
> Generado a partir de la conversación de planificación inicial.

Contexto del proyecto

Objetivo: Construir un pipeline que permita anonimizar datos sensibles de e-commerce antes de exportarlos a entornos cloud (Claude Code, herramientas de analytics SaaS, etc.) sin violar GDPR ni PCI-DSS.

Por qué este proyecto:

- Demuestra dominio avanzado de SQL (técnica principal del proyecto).
- Demuestra conciencia de seguridad de datos sensibles — diferenciador clave en el mercado.
- Combina SQL + Python + LLMs locales (Ollama) — stack moderno y completo.
- Resuelve un problema real que tienen literalmente todas las empresas con tráfico europeo.

Posicionamiento: Trabajo remoto, sector e-commerce/SaaS internacional.

Escenario ficticio

"NovaShop" — E-commerce internacional con HQ en Dublin/Ámsterdam, vendiendo en UK, Germany, France, Spain, Netherlands. Inglés como idioma corporativo. El equipo de analytics necesita usar herramientas cloud y LLMs sobre datos de clientes sin exponer PII.

Decisión: todo el repo en inglés (README, código, comentarios, datos). Esto refuerza el posicionamiento para trabajo remoto internacional y mejora la calidad de las respuestas de Ollama.

Conceptos clave de privacidad (terminología correcta)

- **Anonimización**: transformación irreversible. No se puede recuperar el dato original.
- **Pseudonimización**: identificadores reales reemplazados por artificiales, pero con tabla de equivalencia guardada aparte.
- **Masking (enmascaramiento)**: ocultar parcialmente (`4532-****-****-1234`).
- **Synthetic data generation**: datos completamente falsos que mantienen propiedades estadísticas reales.
- **Differential privacy**: ruido matemático para proteger individuos.
- **K-anonymity**: garantizar que ningún grupo tenga menos de K personas.

Importante: evitar la palabra "encriptación" — técnicamente es reversible y no es lo que estamos haciendo.

Arquitectura: división de trabajo SQL vs Ollama

Frase clave para el README:

> *"SQL handles structured data. Ollama handles unstructured data (free text). The pipeline combines both to protect all forms of sensitive information before exporting to the cloud."*

SQL se encarga de columnas con formato predecible (emails, DNIs, fechas, números).

Ollama se encarga de:

1. Detección y anonimización de PII en texto libre (notas, comentarios).
2. Clasificación automática de columnas en datasets nuevos.
3. Generación de datos sintéticos contextualmente realistas.
4. Validación final del dataset anonimizado (¿queda riesgo de re-identificación?).

Esquema de la tabla principal: `customers_orders`

Columna	Tipo	Sensibilidad	Técnica de anonimización
`order_id`	VARCHAR	Baja	Conservar
`customer_id`	VARCHAR	Alta (reversible)	**Hashing (SHA2)**
`full_name`	VARCHAR	Muy alta	**Eliminación / Pseudonimización**
`email`	VARCHAR	Muy alta	**Masking parcial**
`phone`	VARCHAR	Muy alta	**Masking**
`birth_date`	DATE	Alta	**Generalización** (→ rango de edad)
`gender`	VARCHAR	Media	Conservar
`country`	VARCHAR	Baja	Conservar
`city`	VARCHAR	Media	Conservar
`postal_code`	VARCHAR	Alta	**Generalización** (primeros dígitos)
`street_address`	VARCHAR	Muy alta	**Eliminación**

Columna	Tipo	Sensibilidad	Técnica de anonimización
`card_last4`	VARCHAR	Media	**Masking**
`payment_method`	VARCHAR	Baja	Conservar
`order_date`	DATETIME	Media	**Generalización** (→ semana/mes)
`product_category`	VARCHAR	Baja	Conservar
`order_value_eur`	DECIMAL	Media	**Noise injection** (±5%)
`device_type`	VARCHAR	Baja	Conservar
`ip_address`	VARCHAR	Alta	**Truncamiento** (últimos octetos → 0)
`customer_segment`	VARCHAR	Baja	**K-anonymity check**
`customer_notes`	TEXT	Impredecible	**Ollama (PII detection)** ⭐

Volumen objetivo: 3.000-5.000 filas, de las cuales ~800-1.000 con notas.

Roadmap (6 fases)

Fase 1 — Diseño y setup (1-2 días) ✅ EN PROGRESO

- Definir caso de uso ✅ (NovaShop, e-commerce internacional)
- Clasificación de datos sensibles ✅ (tabla anterior)
- Instalar Ollama y elegir modelo (`llama3.2:3b`)
- Estructura del repo en GitHub

Fase 2 — Generación del dataset (2-3 días)

- 2.1: Setup Python + librerías + verificación Ollama
- 2.2: Generar columnas estructuradas con Faker (multi-locale: en_GB, en_IE, de_DE, fr_FR, es_ES, nl_NL)
- 2.3: Generar `customer_notes` con Ollama, usando datos estructurados como contexto

Fase 3 — Toolkit SQL de anonimización (4-5 días) — CORAZÓN DEL PROYECTO

Una query `.sql` por técnica, todas numeradas:

- Masking (string functions: CONCAT, SUBSTRING, REPEAT)
- Hashing (SHA2)

- Generalización temporal (fechas → rangos)
- Generalización geográfica (códigos postales)
- Agregación k-anónima (GROUP BY + HAVING COUNT >= K)
- Shuffling
- Supresión condicional
- Noise injection

Fase 4 — Capa de Ollama (3-4 días)

- Detección de PII en texto libre
- Clasificación automática de columnas
- Validación de privacidad post-anonimización

Fase 5 — Empaquetar como skill reutilizable (2-3 días)

- Script Python que recibe CSV crudo → devuelve CSV anonimizado + reporte

Fase 6 — Documentación y storytelling (2-3 días)

- README profesional con diagramas de arquitectura
- Notebook end-to-end demo
- Sección de amenazas y limitaciones (madurez técnica)
- Post de LinkedIn

Estructura del repositorio

```
privacy-preserving-ecommerce-pipeline/
├── README.md
├── .gitignore
├── requirements.txt
├── data/
|   ├── raw/                        (gitignored)
|   |   └── .gitkeep
|   └── anonymized/                 (gitignored)
|       └── .gitkeep
├── scripts/
|   ├── 01_generate_dataset.py
|   ├── 02_load_to_mysql.py
|   └── 03_run_pipeline.py
├── sql/
|   ├── 01_create_schema.sql
```

```
|   ├── 02_masking_email.sql
|   ├── 03_masking_phone.sql
|   ├── 04_hashing_customer_id.sql
|   ├── 05_generalize_birthdate.sql
|   ├── 06_generalize_postal_code.sql
|   ├── 07_noise_injection_order_value.sql
|   ├── 08_truncate_ip.sql
|   ├── 09_k_anonymity_check.sql
|   └── 10_full_anonymization_pipeline.sql
├── ollama/
|   ├── anonymize_notes.py
|   └── prompts/
|       └── pii_detection_prompt.txt
├── docs/
|   ├── architecture.md
|   ├── techniques_explained.md
|   ├── compliance.md                       (GDPR + PCI-DSS mapping)
|   └── project_planning_conversation.md    (este documento)
└── notebooks/
    └── end_to_end_demo.ipynb
```

Stack técnico

- **MySQL** (motor de base de datos)
- **Python 3.x** con entorno virtual (`venv`)
- **Ollama** con `llama3.2:3b` (LLM local)
- **Librerías Python**: faker, pandas, mysql-connector-python, ollama, python-dotenv

---

Setup checklist

- [ ] Ollama corriendo (`http://localhost:11434` responde)
- [ ] Modelo `llama3.2:3b` descargado (`ollama list`)
- [ ] Modelo prueba (`ollama run llama3.2:3b` → respuesta coherente)
- [ ] Carpeta del proyecto creada con estructura
- [ ] Entorno virtual Python activo (`venv`)
- [ ] Librerías instaladas (`pip install ...`)
- [ ] `requirements.txt` generado
- [ ] `.gitignore` creado (incluye venv/, .env, data/raw/*.csv, data/anonymized/*.csv)
- [ ] `test_ollama.py` ejecutado con éxito

Buenas prácticas acordadas

1. **No usar datos reales bajo ninguna circunstancia.** Todo sintético desde el inicio.
2. **Credenciales en** `.env`, nunca en código (encaja con la temática del proyecto).
3. **Comentar el código** explicando el "por qué" de cada técnica de anonimización.
4. **Reconocer limitaciones** en el README (madurez técnica > pretensión).
5. **Mencionar frameworks legales** (GDPR, PCI-DSS) para mostrar conciencia de negocio.
6. **No reinventar criptografía** — usar funciones SQL estándar (SHA2, AES_ENCRYPT).
7. **Repo enteramente en inglés** para coherencia con posicionamiento remoto internacional.

Próximo paso inmediato

Completar el setup checklist y avisar cuando `test_ollama.py` devuelva respuesta. A partir de ahí, arrancar el script `01_generate_dataset.py` (Fase 2.2 — generación de columnas estructuradas con Faker multi-locale).

Narrativa para entrevistas

> *"I worked in e-commerce managing Shopify and Meta Ads campaigns. In that role I started thinking about how my company handled sensitive customer data — emails, addresses, purchase history — especially when we wanted to use AI or cloud tools to analyze that data. That led me to build this project: an anonymization pipeline that allows advanced analytics on customer data without exposing personal information."*